

Laboratorio 8

Humberto Alexander de la Cruz - 23735
Daniel Oswaldo Juárez Herrera - 23709
Dilary Sarahí Cruz López - 231010

Task 2.2

La perplejidad de validación del Mini-GPT fue de **7.12** (rango esperado: 3.5–8.0), con pérdida final de 1.89 en entrenamiento y 1.96 en validación tras 10 épocas. Las cinco muestras de la configuración A son idénticas porque greedy es determinista.

Diversidad medida sobre las 5 muestras de 200 caracteres de cada configuración:

Config.	Caracteres únicos	Trigramas repetidos	Palabras reales
A (greedy)	10.0	89.39 %	100.00 %
B (top- $k=5$, $\tau=0.7$)	29.6	35.15 %	86.61 %
C (top- $k=50$, $\tau=1.0$)	38.2	7.78 %	53.12 %
D (top- $p=0.70$, $\tau=0.7$)	26.2	41.52 %	93.47 %
E (top- $p=0.95$, $\tau=1.0$)	38.4	10.40 %	59.36 %

a. Greedy (configuración A)

Greedy elige $w_t = \arg \max_i P(w_i \mid w_{<t})$. Es una función determinista del contexto: cuando el modelo vuelve a un contexto casi igual al de antes, produce exactamente la misma salida y entra en un ciclo. En las muestras A el texto colapsa a **The so the so the the the here the the the the the...**: tras un espacio el carácter más probable inicia **the**, y tras **the** vuelve a ser **the**.

La distribución aprendida para el siguiente carácter tiene entropía considerable (pérdida ≈ 1.96 nats, perplejidad ≈ 7 : hay varios caracteres plausibles), pero greedy ignora toda la masa fuera de la moda y siempre toma el patrón más frecuente del corpus. Al no haber aleatoriedad, nada rompe el ciclo. Las métricas lo confirman: A usa 10 caracteres únicos por muestra y el 89 % de sus trigramas están repetidos, frente a 8–10 % en C y E.

b. Configuraciones B y C

Con

$$P(w_i \mid \text{ctx}) = \frac{\exp(z_i/\tau)}{\sum_j \exp(z_j/\tau)} :$$

- **Aumentar k de 5 a 50.** Con solo 65 caracteres, $k = 50$ casi no recorta la distribución: quedan candidatos con probabilidad muy baja (letras raras, signos) que pueden ser muestreados, por lo que aumenta la diversidad. C tiene 38.2 caracteres únicos por muestra frente a 29.6 en B, y 7.8 % de trigramas repetidos frente a 35 %.

- **Aumentar τ de 0.7 a 1.0.** Dividir por $\tau < 1$ amplifica las diferencias entre logits ($z_i/0,7$) y concentra la masa en los primeros tokens (menor entropía); con $\tau = 1$ la distribución queda como la aprendió el modelo, más plana. Ambos cambios apuntan en la misma dirección: más aleatoriedad en C.
- **Coherencia vs. creatividad.** B es la más coherente: 86.6 % de sus palabras existen en el corpus y tiene estructura reconocible (`And that the so strand of here hish here shall`, líneas de diálogo como PUCARCETIO:), aunque abusa de palabras frecuentes (`the`, `and`, `here`). C es la más creativa y ruidosa: mayor variedad, pero solo 53 % de palabras reales y neologismos como `Quet Gancue that shee prorend o nconge of foulht`.

c. Configuración E ($\text{top-}p = 0,95$, $\tau = 1,0$)

El tamaño del conjunto candidato (menor conjunto con masa acumulada $\geq 0,95$) refleja la certeza del modelo: pocos candidatos indica seguridad y muchos indica inseguridad. Lo que sigue se infiere de las muestras; no se registró el tamaño del núcleo en cada paso.

Momentos de alta certeza.

1. El salto de línea tras los dos puntos del nombre de un personaje: `ROMEO: → \n`, `MELICIONGA: → \n` (E2) y `KINGHCHELAS: → \n` (E1).
2. El interior de palabras cuyo prefijo casi determina la continuación, por ejemplo `Thou`, `death` y `hand` en E1, E2 y E5 (tras `dea` o `han` la siguiente letra es casi forzada), y el espacio tras palabras completas como `the` o `and`.

Momentos de incertidumbre.

1. Los nombres de personaje inventados al inicio de línea (`MELICIONGA`, `BUTULOLIUS`, `FRICIRHAF` en E2, E5 y E3), donde puede venir casi cualquier mayúscula.
2. El primer carácter de una palabra poco frecuente tras un espacio o signo de puntuación, donde el modelo divaga: `mugger edvikig hing` (E1), `espeaither dearsiong` (E4).

En resumen, los signos estructurales (`:` $\rightarrow$ `\n`) y la mitad de las palabras son posiciones seguras; los inicios de línea o de palabra y los nombres propios son inciertos.